

河北工程大学

《经济与金融大数据实践》

基于电商用户行为数据的购买转化预测与 营销策略分析

专业 数据科学与大数据技术

班级 2202

学号 220620222

姓名 龙军利

目录

一、引言	1
1.1 研究背景与现实意义	1
1.2 研究目标与主要内容	1
1.3 作业要求完成情况说明	1
二、数据采集与探索性分析	2
2.1 数据来源与字段说明	2
2.2 数据探索性分析	3
2.2.1.基础统计分析	3
2.2.2 用户行为分布分析	4
2.2.3 时间特征分析	4
2.2.4 商品分类热度分析	5
2.2.5 性别-行为相关性分析	6
三、数据预处理	7
3.1 数据清洗	7
3.2 数据转换	7
3.3 特征工程	7
四、数据分析与建模	8
4.1 模型选择与原理	8
4.2 数据准备与模型训练	8
4.3 模型性能评估	9
五、预测与结果分析	12
5.1 购买趋势预测	12
5.2 关键发现分析	12
5.3 精细化营销策略建议	13
六、结论与展望	13
6.1 研究结论	13
6.2 研究局限与展望	13
参考文献	14

题目：基于电商用户行为数据的购买转化预测与营销策略分析

一、引言

1.1 研究背景与现实意义

在数字经济快速发展的背景下，电商平台积累了海量用户行为数据，这些数据包含用户浏览、收藏、加购、购买等多维度行为信息，是挖掘用户消费偏好、提升购买转化率的核心资产。当前电商行业面临“流量红利见顶”“用户转化成本上升”等挑战，如何通过大数据分析技术精准识别潜在购买用户、优化营销资源配置，成为平台提升竞争力的关键问题。

本研究基于真实电商用户行为数据，通过数据挖掘与机器学习方法，构建购买转化预测模型，识别影响用户购买决策的关键因素，为电商平台制定精细化营销策略提供数据支撑，具有重要的现实应用价值。

1.2 研究目标与主要内容

1. 研究目标：基于电商用户行为数据，实现用户购买行为的精准预测，识别高价值用户群体与关键影响因素，提出可落地的营销优化策略。

2. 主要内容：

- 数据采集与探索性分析，揭示用户行为分布特征与数据规律；
- 数据预处理与特征工程，构建适配建模的高质量特征体系；
- 构建逻辑回归与 SVM 分类模型，实现购买行为预测与模型性能评估；
- 基于 K-Means 聚类进行用户分群，结合预测结果提出差异化营销策略。

1.3 作业要求完成情况说明

本研究严格按照《经济与金融大数据实践作业要求》完成全部核心任务：

1. 数据采集：使用公开电商用户行为数据集 <https://www.kaggle.com/data>

[sets/qc2033862865/e-commerce-user-data](#), 明确标注数据来源与字段含义, 满足数据可得性要求;

- 2. 数据探索: 完成描述性统计与相关性分析, 生成 8 类可视化图表, 全面展示数据特征;
- 3. 数据预处理: 详细完成缺失值、异常值处理与特征工程, 构建 7 个衍生特征;
- 4. 数据分析与建模: 运用逻辑回归、SVM 分类算法与 K-Means 聚类算法, 完成模型训练与性能评估;
- 5. 预测与结果分析: 基于模型结果预测消费趋势, 提出 3 类精细化营销策略, 图表均带编号与标题并在正文引用。

二、数据采集与探索性分析

2.1 数据来源与字段说明

本研究使用的电商用户行为数据来源于公开电商平台用户行为日志, 数据规模为 764833 条记录 [UserBehavior--1.csv](#), 包含 11 个核心字段。为清晰展示数据结构, 现将数据表头及字段含义说明如下:

字段名	数据类型	字段含义说明
user_id	整数型	用户唯一标识, 用于追踪用户跨时间维度的行为轨迹
goods_id	整数型	商品唯一标识, 用于关联用户与商品的交互关系
category_id	整数型	商品分类唯一标识, 用于分析用户品类偏好
behavior	字符串型	用户行为类型, 包含 pv (浏览)、cart (加购)、fav (收藏)、buy (购买) 四类
timestamp	字符串型	行为发生的时间戳 (秒级), 用于时间特征提取
sex	整数型	用户性别, 0 表示男性, 1 表示女性, 用于分析性别差异
address	字符串型	用户所在城市, 用于地域偏好分析
device	字符串型	用户访问设备 (如 Redmi、moto), 用于设备偏好分析
price	浮点型	商品价格 (单位: 元), 部分记录为 0 表示未标注价格

字段名	数据类型	字段含义说明
amount	整数型	购买数量，非购买行为时为 0
comment	字符串型	用户购买后评论内容，非购买行为时为缺失值

表 1 数据表头及字段含义

2.2 数据探索性分析

2.2.1.基础统计分析

对核心数值型字段进行描述性统计，结果如下表所示：

统计指标	user_id	goods_id	category_id	price（元）	amount	sex
样本数	764833.00	764833.00	764833.00	764833.00	764833.00	764833.00
均值	5761.42	2140077.79	2710476.01	0.95	0.05	0.43
标准差	9197.12	5410040.21	1459465.05	7.88	0.37	0.49
最小值	2.00	-89913091.00	2171.00	0.00	0.00	0.00
25%分位数	2849.00	1266711.00	1379146.00	0.00	0.00	0.00
50%分位数	5711.00	2559592.00	2690374.00	0.00	0.00	0.00
75%分位数	8396.00	3848816.00	4145813.00	0.00	0.00	1.00
最大值	937166.00	5163006.00	5161669.00	99.90	4.00	1.00

表 2 核心数值型字段进行描述性统计

统计结果显示：用户行为数据覆盖广泛，商品价格均值为 0.95 元（受大量 0 值影响），最高价格 99.90 元；性别分布相对均衡，女性用户占比 43%；购买数

量均值仅 0.05，说明大部分用户未产生购买行为，转化潜力较大。

2.2.2 用户行为分布分析

用户行为类型分布如下图所示，浏览行为（pv）占比 89.8%，购买行为（buy）仅占 1.9%，加购（cart）和收藏（fav）分别占 5.6%和 2.7%。这一分布符合电商行业“高浏览、低转化”的普遍特征，也验证了提升购买转化率的必要性。

图1 电商用户行为分布




图 1 电商用户行为分布饼状图

2.2.3 时间特征分析

用户活跃时段分布如下图所示，0:00-1:00 为活跃高峰时段，行为次数达

65290 次，推测与夜间碎片化浏览习惯相关；此外 19:00-22:00 时段也呈现较高活跃度，符合用户下班后的购物行为规律。




图 2 电商用户活跃时段分布树状图

2.2.4 商品分类热度分析

热门商品分类 Top10 分布如下图所示，分类 4756105 的累计行为次数最高（41445 次），分类 4145813（36076 次）和 2355072（28611 次）紧随其后，三类热门分类累计占比达 35.2%，说明用户消费偏好相对集中。




图 3 热门商品分类 Top10 树状图

2.2.5 性别-行为相关性分析

不同性别用户的行为占比如下图所示，男性用户购买占比 1.95%，女性用户购买占比 1.90%，差异较小；女性用户加购占比（5.88%）高于男性（5.46%），说明女性用户的购物决策更倾向于“先加购再决策”。




图 4 不同性别用户的行为占比热力图

性别与各行为的相关性热力图显示，性别与加购行为的相关性最高（0.0091），与浏览行为相关性最低（-0.0059），整体相关性较弱，说明性别对用户行为的影响有限。




图 5 性别与各用户行为的相关性热力图

三、数据预处理

3.1 数据清洗

1.缺失值处理：核心字段（`user_id`、`goods_id`、`behavior`、`timestamp`）无缺失值；性别字段用众数填充，价格、数量字段缺失值填充为 0，地址、设备、评论字段缺失值分别填充为“未知”“未知”“无评论”，最终保留 757565 条有效记录。

2.重复值处理：删除完全重复记录与“用户-商品-行为-时间戳”复合主键重复记录，无重复记录需删除。

3.异常值处理：价格字段采用 99 分位数（47.60 元）截断极端高价；数量字段限制取值范围为 0-100，剔除异常大值与负值。

3.2 数据转换

1.时间格式转换：将 `timestamp` 字符串转换为 `datetime` 格式，提取小时（`hour`）、星期（`weekday`）等时间特征；

2.数据类型转换：确保数值型字段（如 `price`、`amount`）为浮点型/整数型，适配建模要求；

3.标签定义：将购买行为（`buy`）标记为 1，非购买行为（`pv`、`cart`、`fav`）标记为 0，构建二分类任务标签。

3.3 特征工程

为提升模型预测性能，构建 7 个衍生特征，具体如下：

1.`user_goods_count`：用户对同一商品的浏览次数，反映用户对特定商品的兴趣强度；

2.`is_hot_category`：是否为热门分类（Top3 分类标记为 1，其余为 0）；

3.`total_behavior_count`：用户总行为次数，反映用户活跃度；

4.`browse_goods_types`：用户浏览的商品种类数，反映用户兴趣广度；

5.goods_hot_score: 商品被所有用户的行为次数, 反映商品热度;

6.is_peak_hour: 是否为高峰时段 (0:00-1:00 标记为 1, 其余为 0);

7.is_weekend: 是否为周末 (周六、周日标记为 1, 其余为 0)。

预处理后的数据已保存为“预处理后的数据.csv”, 最终数据包含 22 个字段, 为后续建模提供高质量数据支撑。

四、数据分析与建模

4.1 模型选择与原理

1.逻辑回归: 作为基础分类模型, 具有易解释性强、训练速度快的特点, 适合作为基准模型, 通过 sigmoid 函数将输出映射到[0,1]区间, 实现购买概率预测;

2.SVM (支持向量机): 采用线性核函数, 适合高维数据分类, 通过最大化分类间隔提升模型泛化能力, 适配用户行为数据的特征维度;

3.K-Means 聚类: 无监督学习算法, 基于特征相似度将用户分为 3 类, 实现高价值用户识别。

4.2 数据准备与模型训练

1.特征选择: 选取 8 个核心特征 (sex、browse_goods_types、total_behavior_count、goods_hot_score、is_peak_hour、is_weekend、user_goods_count、is_hot_category) 构建建模特征集;

2.数据分割: 按 7:3 比例分割训练集 (530295 条) 与测试集 (227270 条), 采用分层抽样保持正负样本分布一致;

3.数据标准化: 使用 StandardScaler 对特征进行标准化处理, 消除量纲影响;

4.模型训练: 逻辑回归采用 L2 正则化与类别平衡权重; SVM 采用线性核函数, 训练集抽样 10% (53029 条) 提升训练效率; K-Means 聚类设置簇数为 3。

4.3 模型性能评估

1.评估指标：选用准确率、精确率、召回率、F1 分数、AUC 分数作为核心评估指标，全面衡量模型性能；

2.交叉验证：逻辑回归采用 5 折交叉验证，确保模型性能稳定。

模型性能评估结果如下表所示：

评估指标	逻辑回归	逻辑回归交叉验证（均值±标准差）	SVM
准确率	0.6838	0.6804±0.0094	0.1258
精确率	0.0421	0.0417±0.0012	0.0202
召回率	0.7086	0.7097±0.0099	0.9346
F1 分数	0.0794	0.0788±0.0022	0.0395
AUC 分数	0.7551	-	0.5738

表 3 模型性能评估

模型性能对比可视化如下：




图 6 模型性能对比

结果分析：逻辑回归模型综合性能更优，AUC 分数达 0.7551，说明具有良

好的购买预测能力；SVM 模型召回率虽高（93.46%），但精确率极低，存在大量误判；交叉验证结果显示逻辑回归性能稳定，无明显过拟合现象。

3.特征重要性分析

逻辑回归模型的特征重要性如下图所示，用户性别（sex）、是否周末（is_weekend）、是否高峰时段（is_peak_hour）是影响购买行为的 Top3 关键特征，商品热度与用户浏览行为特征也具有一定影响。




图 7 特征重要性排名（逻辑回归）

4.用户分群结果

K-Means 聚类将用户分为 3 个集群，各集群购买转化率如下：

- 集群 1（486648 人）：购买转化率 2.42%，为高价值用户群体；
- 集群 0（176123 人）：购买转化率 1.27%，为中等价值用户群体；
- 集群 2（94794 人）：购买转化率 0.59%，为低价值用户群体。

用户分群转化率对比可视化如下：

图8 各集群用户购买转化率对比




图 8 各集群用户购买转化率对比

5.PR 曲线分析

精确率-召回率曲线（PR 曲线）如下图所示，逻辑回归模型在全召回率区间的精确率均高于 SVM 模型，进一步验证了逻辑回归的优越性，适合电商场景下“精准识别潜在购买用户”的核心需求。

图9 精确率-召回率曲线（PR曲线）




图 9 精准率-召回率曲线（pr 曲线）

五、预测与结果分析

5.1 购买趋势预测

基于 7 日移动平均法对短期（1 个月）购买转化率进行预测，结果显示未来 1 个月购买转化率预计达 1.98%，较当前提升 3.1%；热门商品分类（4756105、4145813、2355072）需求将持续增长，建议重点关注。

日购买转化率趋势如下图所示，整体转化率呈小幅波动上升趋势，验证了预测的合理性。




图 10 日购买转化率趋势

5.2 关键发现分析

1.用户行为特征：浏览行为占绝对主导（89.8%），但购买转化率仅 1.92%，存在巨大转化提升空间；

2.时间特征：0:00-1:00 为活跃高峰，但转化率（1.60%）略低于非高峰时段（1.96%），推测夜间浏览用户决策谨慎；

3.用户分群特征：高价值用户（集群 1）占比 64.2%，购买转化率是低价值用户（集群 2）的 4.1 倍，用户价值分化明显；

4.影响因素：性别、时段、商品热度是影响购买的核心因素，为营销策略制

定提供明确方向。

5.3 精细化营销策略建议

1.高价值用户运营策略：针对集群 1 用户（购买转化率 2.42%），建立专属会员体系，推送热门分类（4756105、4145813、2355072）高热度商品，搭配限时折扣与免运费权益，提升复购率；

2.时段营销优化策略：虽然 0:00-1:00 活跃度高但转化率低，可推出“夜间专属优惠券”（有效期至次日 24 点），刺激即时购买；19:00-22:00 时段叠加直播带货与限时秒杀，强化购买决策；

3.商品布局调整策略：加大 Top3 热门分类商品的库存与曝光力度，在首页设置“热门分类专区”；针对用户浏览次数 ≥ 3 次的商品，触发“加购立减”弹窗，降低转化门槛。

六、结论与展望

6.1 研究结论

本研究基于 764833 条电商用户行为数据，完成了从数据探索、预处理到建模分析的全流程研究，主要结论如下：

1.数据层面：电商用户行为呈现“高浏览、低转化”特征，用户活跃度与商品热度分布不均，存在明显的时段与品类偏好；

2.模型层面：逻辑回归模型在购买转化预测任务中表现最优（AUC=0.7551），性别、时段、商品热度是关键预测因素；

3.应用层面：通过 K-Means 聚类识别出高、中、低三类价值用户群体，差异化营销策略可有效提升转化效率。

6.2 研究局限与展望

1.研究局限：数据中价格字段大量为 0，可能影响模型对价格敏感用户的识

别；未纳入用户历史购买记录、商品评价等外部数据；

2.未来展望：可补充商品属性、用户历史订单等多源数据，提升模型预测精度；尝试 LSTM 等深度学习模型捕捉用户行为时序特征；结合 A/B 测试验证营销策略的实际效果，形成“分析-建模-落地-验证”的闭环。

参考文献

- [1] 商务部电子商务司。商务部电子商务司负责人介绍 2025 年 1—10 月我国电子商务发展情况 [EB/OL]. https://www.gov.cn/lianbo/fabu/202511/content_7049078.htm, 2025-11-20.
- [2] 原创力文档研究团队. 2025 年电子商务平台用户行为分析与忠诚度提升研究报告 [R]. <https://m.book118.com/html/2025/1107/7150125054011006.shtm>, 2025-11-08.
- [3] Shopify 中国团队。电商营销策略：26 个策略助你提升流量和销售 [EB/OL]. <https://zh.shopify.com/blog/ecommerce-marketing>, 2025-11-05.
- [4] 探索创业之道研究组。现在电商行业还赚钱吗？探索创业之道 [EB/OL]. http://m.toutiao.com/group/7583973379795960363/?upstream_biz=doubao, 2025-12-15.
- [5] 人人文库数据研究中心。电商平台的用户行为分析与研究报告 [R]. <https://www.renrendoc.com/paper/489771769.html>, 2025-11-10.
- [6] Amazon 全球开店团队。电子商务营销：2025 年提升线上销售额的 11 种策略 [EB/OL]. <https://sell.amazon.com/zh/learn/ecommerce-marketing>, 2025-11-26.
- [7] 艾瑞咨询. 2025 年中国电商用户行为白皮书 [R]. 北京：艾瑞咨询集团，2025.
- [8] 易观分析. 2025 年中国电子商务用户忠诚度管理研究报告 [R]. 北京：易观分析，2025.